

Dokumentacja końcowa projektu UMA

Jan Szwagierczak, Tomasz Okoń

23 stycznia 2026

1 Treść zadania

„Połączenie lasu losowego z SVM w zadaniu klasyfikacji. Postępujemy tak jak przy tworzeniu lasu losowego, tylko pewien procent klasyfikatorów w lesie to SVM. Jeden z klasyfikatorów (SVM lub drzewo ID3) może pochodzić z istniejącej implementacji.”

2 Algorytmy i struktura rozwiązania

W projekcie zaimplementowano hybrydowy zespół klasyfikatorów, łączący autorską implementację drzewa decyzyjnego ID3 z bibliotecznym klasyfikatorem SVM.

2.1 Autorskie drzewo ID3

Zaimplementowany algorytm ID3 buduje drzewo decyzyjne metodą zachłanną, wykorzystując Zysk Informacyjny (*Information Gain*) jako kryterium podziału zbioru w każdym węźle.

Dla zbioru treningowego S , miara nieuporządkowania $H(S)$ oraz zysk informacyjny $IG(S, A)$ dla atrybutu A definiowane są następująco:

$$H(S) = - \sum_{i=1}^k p_i \log_2(p_i), \quad IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

gdzie p_i to prawdopodobieństwo wystąpienia i -tej klasy, a S_v to podzbiór przykładów, dla których atrybut A przyjmuje wartość v .

Procedura budowy drzewa jest rekurencyjna: w każdym kroku wybierany jest atrybut z największym zyskiem informacyjnym, a zbiór dzielony jest na podzbiory, aż do uzyskania takich samych klas w liściach lub wyczerpania atrybutów.

2.2 Support Vector Machine (SVM)

Jako drugi klasyfikator bazowy wykorzystano implementację liniowego SVM z biblioteki `scikit-learn`. Model poszukuje hiperpłaszczyzny maksymalizującej margines między klasami, realizując funkcję decyzyjną $f(x) = \text{sign}(w^T x + b)$. Proces uczenia polega na minimalizacji funkcji:

$$\frac{1}{2} \|w\|^2 + C \sum_i \xi_i,$$

gdzie parametr C reguluje kompromis między marginesem a błędami klasyfikacji. Dla problemów wieloklasowych zastosowano strategię *One-vs-Rest*.

2.3 Algorytm Lasu

Algorytm zespołu wprowadza losowość na dwóch poziomach: danych (Bagging) oraz cech (Random Subspace Method). Procedura uczenia dla T estymatorów przebiega następująco:

1. Dla każdego estymatora $i = 1 \dots T$:

- Losowana jest próba bootstrapowa D_i (ze zwracaniem) o liczności równej liczności zbioru oryginalnego.
 - Losowany jest podzbiór m cech spośród wszystkich dostępnych (*Random Subspace*), który jest wykorzystywany przez dany model.
 - Z prawdopodobieństwem p_{svm} trenowany jest klasyfikator SVM (na danych ciągłych/One-Hot), w przeciwnym razie $(1 - p_{svm})$ budowane jest drzewo ID3 (na danych dyskretnych).
2. Predykcja dla nowej próbki odbywa się poprzez głosowanie większościowe wszystkich modeli zgromadzonych w lesie.

2.4 Odstępstwa i doprecyzowanie implementacji

W stosunku do pierwotnych założeń wprowadzono następujące doprecyzowania:

- **Random Subspace Method:** Aby zapewnić różnorodność klasyfikatorów, wprowadzono losowanie podzbioru cech dla każdego estymatora. Wartość m (liczba cech używanych przez pojedynczy klasyfikator) domyślnie ustawiono na $\sqrt{M}$ (gdzie M to liczba cech), z dynamicznym dostosowaniem dla zbiorów o bardzo małej liczbie atrybutów.
- **Obsługa danych heterogenicznych:** Las obsługuje jednocześnie dwie reprezentacje danych: dyskretną (dla ID3) oraz ciągłą/zakodowaną One-Hot (dla SVM), przekazując do konkretnego estymatora odpowiedni format danych wejściowych.
- **Syntetyczny zbiór danych:** Wygenerowano dodatkowy zbiór *Synthetic Diagonal*, w którym granica decyzyjna jest zdefiniowana jako hiperpłaszczyzna $\sum_{i=1}^{10} x_i = 5$. Zbiór ten został stworzony w celu wprowadzenia przykładu, gdzie liniowy SVM ma przewagę nad drzewami decyzyjnymi.

2.5 Weryfikacja poprawności (Testy)

Aby upewnić się, że implementacja nie zawiera błędów, przeprowadzono:

1. **Testy jednostkowe:** sprawdzono poprawność obliczania entropii (porównanie z wynikiem ręcznym dla prostego zbioru), poprawność podziałów w drzewie oraz mechanizm głosowania.
2. **Porównanie z metodą referencyjną:** wyniki autorskiego drzewa ID3 porównano z `DecisionTreeClassifier` na zbiorze *Mushroom*. Uzyskano zgodność wyników (dokładność $\approx 100\%$), co potwierdza poprawność logiki budowy drzewa.

3 Metodyka badań

3.1 Zbiory danych

Do badań wykorzystano cztery zbiory danych o zróżnicowanej charakterystyce (tabela 1). Zbiór *Mushroom* pełni funkcję weryfikacyjną. Zbiory ciągłe (*Breast Cancer*, *Wine*) zostały poddane dyskretyzacji dla algorytmu ID3 (metoda kubelkowa), natomiast zbiory dyskretne (*Mushroom*, *Car Evaluation*) zostały zakodowane metodą One-Hot Encoding na potrzeby klasyfikatora SVM.

Tabela 1: Charakterystyka zbiorów danych

Nazwa zbioru	Liczba przykładów	Liczba cech	Typ cech	Liczba klas
Mushroom	8124	22	Kategoryczne	2
Wisconsin Breast Cancer	569	30	Ciągłe	2
Wine Quality (Red)	1599	11	Ciągłe	2
Car Evaluation	1728	6	Kategoryczne	4
Synthetic Diagonal	925	10	Ciągłe	2

Szczegółowy rozkład klas w zbiorach:

- **Mushroom:** 4208 (edible), 3916 (poisonous) - zbiór zbalansowany.
- **Wisconsin Breast Cancer:** 357 (benign), 212 (malignant) - zbiór lekko niezbalansowany.
- **Wine Quality (Red):** 744 (low quality), 855 (high quality) - zbiór lekko niezbalansowany. Zastosowano binaryzację etykiet, przyjmując próg jakości $\text{quality} \geq 6$ jako klasę pozytywną.
- **Car Evaluation:** 1210 (unacc), 384 (acc), 69 (good), 65 (vgood) - zbiór silnie niezbalansowany.
- **Synthetic Diagonal:** Zbiór wygenerowany specjalnie do testów. Granica decyzyjna zdefiniowana jest jako hiperpłaszczyzna. Teoretycznie faworyzuje klasyfikatory liniowe (SVM), a jest trudny dla drzew decyzyjnych (problem aproksymacji schodkowej).

3.2 Procedura eksperymentalna

Każdy eksperyment przeprowadzono zgodnie z poniższymi zasadami, aby zapewnić rzetelność i powtarzalność wyników:

- **Wielokrotne uruchomienia:** Każdy pomiar stanowi średnią z 25 niezależnych uruchomień algorytmu. W każdej iteracji stosowano inne ziarno losowości (`random_state`).
- **Weryfikacja poprawności:** Przed przystąpieniem do głównych eksperymentów wykonano testy jednostkowe oraz porównano wyniki autorskiej implementacji z metodami referencyjnymi (biblioteka `scikit-learn`).
- **Podział danych:** Zastosowano 5-krotną walidację krzyżową, co w połączeniu z 25 powtórzeniami daje łącznie 125 prób trenowania dla każdej konfiguracji parametrów.
- **Miary jakości:** Raportowana jest średnia dokładność (Accuracy), odchylenie standardowe, wynik minimalny i maksymalny oraz zagregowane macierze pomyłek (sumowane ze wszystkich uruchomień).

4 Wyniki eksperymentów

4.1 Weryfikacja

W celu weryfikacji poprawności implementacji porównano wyniki autorskiego drzewa ID3 oraz modelu hybrydowego z implementacjami referencyjnymi z biblioteki `scikit-learn`. Odpowiednio:

- ID3 - autorska implementacja drzewa decyzyjnego,
- SkTree - `DecisionTreeClassifier` z biblioteki `scikit-learn`,
- RF - autorska implementacja lasu, parametry: liczba estymatorów $T = 50$, $p_{svm} = 0\%$ - czyli czysty las z drzew ID3,
- SkRF - `RandomForestClassifier` z biblioteki `scikit-learn`, parametry: liczba estymatorów $T = 50$, domyślne ustawienia pozostałych parametrów.
- Hybrid - autorska implementacja lasu, parametry optymalne: $T = 50$, $p_{svm} = 50\%$, $C = 10,0$,
- H-RF Diff - różnica dokładności między modelem hybrydowym a referencyjnym lasem losowym (Hybrid - RF).

Tabela 2: Porównanie dokładności implementacji autorskich z referencyjnymi

Zbiór danych	ID3	SkTree	RF	SkRF	Hybrid	H-RF Diff
Mushroom	1,0000	1,0000	0,9934	1,0000	1,0000	+0,0066
Breast Cancer	0,9240	0,9240	0,9415	0,9415	0,9591	+0,0175
Wine Quality	0,7458	0,7542	0,7438	0,7812	0,7292	-0,0146
Car Evaluation	0,9383	0,9750	0,8035	0,9692	0,7784	-0,0250
Synthetic Diagonal	0,6691	0,7734	0,8201	0,8813	0,9317	+0,1115


Wnioski:

Porównanie z metodami referencyjnymi wykazało poprawność implementacji autorskiego drzewa ID3 oraz lasu losowego (ID3 vs SkTree oraz RF vs SkRF).


Na zbiorze Mushroom, dzięki prostej separowalności, model hybrydowy osiąga perfekcyjny wynik (1,0000), nieznacznie przewyższając czysty las ID3 (0,9934), co może wynikać z efektywności SVM na tym zbiorze lub losowości modelu RF. Największą korzyść z hybrydyzacji odnotowano na zbiorze *Synthetic Diagonal* (+11,15 p.p.) oraz *Breast Cancer* (+1,75 p.p.), gdzie połączenie liniowego SVM z drzewami pozwoliło na lepsze modelowanie granicy decyzyjnej. Na zbiorach *Wine Quality* oraz *Car Evaluation*, gdzie relacje są nieliniowe bądź kategoriyczne, model hybrydowy ustępuje czystemu lasowi losowemu, co sugeruje, że dodanie liniowych estymatorów SVM wprowadza tam zakłócenia.

4.2 Scenariusz 1: Wpływ udziału SVM w lesie (p_{svm})


Zbadano wpływ parametru $p_{svm} \in \{0,20,50,80,100\}\%$. Parametr ten określa, jak duża część lasu składa się z klasyfikatorów SVM (reszta to ID3). W eksperymencie ustalono liczbę estymatorów $T = 50$ oraz parametr regularyzacji SVM $C = 10,0$.




(a) Mushroom




(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation



(e) Synthetic Diagonal

Rysunek 1: Średnia dokładność w zależności od udziału SVM (p_{svm}) dla $T = 50$ oraz $C = 10,0$. Słupki błędów oznaczają odchylenie standardowe.

Tabela 3: Szczegółowe wyniki dla zbioru **Wisconsin Breast Cancer** (średnia z 25 uruchomień)

p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,948	0,005	0,939	0,958
20	0,958	0,005	0,949	0,968
50	0,965	0,004	0,958	0,972
80	0,963	0,003	0,958	0,968
100 (Czyste SVM)	0,962	0,003	0,954	0,967

Tabela 4: Szczegółowe wyniki dla zbioru **Wine Quality** (średnia z 25 uruchomień)


p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,757	0,007	0,740	0,769
20	0,753	0,008	0,739	0,767
50	0,743	0,007	0,726	0,760
80	0,727	0,011	0,702	0,749
100 (Czyste SVM)	0,715	0,011	0,689	0,733

Wnioski:


- Na zbiorze Mushroom (rys. 1a) wyniki są zbliżone do 1,0, a obserwowane wahania mają charakter losowy. Oznacza to, że oba typy klasyfikatorów radzą sobie z tym problemem niemal bezbłędnie.
- Na zbiorze Synthetic Diagonal (rys. 1e) widoczna jest wyraźna przewaga SVM. Dokładność rośnie z 82,1% (dla czystego ID3) do 98,0% (dla czystego SVM). Wynika to z geometrii problemu – granica decyzyjna jest "ukośną" hiperpłaszczyzną, co jest prostsze do zamodelowania dla liniowego SVM.
- Na zbiorze Breast Cancer (tab. 3, rys. 1b) hybrydyzacja przyniosła najlepsze rezultaty. Optimum uzyskano dla $p_{svm} = 50\%$ (dokładność 0,965), co jest wynikiem wyższym niż dla czystego ID3 (0,948) oraz czystego SVM (0,962). Sugeruje to, że model hybrydowy skutecznie wykorzystuje różniące się własności zastosowanych klasyfikatorów: drzewo umożliwia modelowanie nieliniowych granic decyzyjnych, a SVM zapewnia liniową separację w przestrzeni cech.
- Na zbiorze Wine Quality (tab. 4, rys. 1c) obserwujemy tendencję spadkową - najlepsze wyniki uzyskano dla czystego ID3 ($p_{svm} = 0\%$, dokładność 0,757), a zwiększanie udziału SVM stopniowo pogarszało jakość klasyfikacji (spadek do 0,715 dla $p_{svm} = 100\%$). Sugeruje to, że relacje w tym zbiorze są nieliniowe i lepiej modelowane przez drzewa decyzyjne niż przez liniowy SVM.
- Na zbiorze Car Evaluation (rys. 1d) odnotowano podobny trend jak dla Wine Quality - spadek jakości wraz ze wzrostem udziału SVM (z 0,831 dla ID3 do 0,794 dla SVM). Relacje w tym zbiorze są silnie nieliniowe i kateryczne, co faworyzuje drzewa decyzyjne.

4.3 Scenariusz 2: Wpływ liczby estymatorów (T)


Zbadano wpływ rozmiaru lasu $T \in \{10, 20, 50, 100\}$ na stabilność i jakość predykcji. W eksperymencie ustalono udział SVM na $p_{svm} = 50\%$ oraz regularyzację $C = 10,0$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation


Rysunek 2: Wpływ liczby estymatorów (T) na średnią dokładność dla różnych zbiorów danych (dla $p_{svm} = 50\%$ oraz $C = 10,0$).

Wnioski:


- Na zbiorze Mushroom (rys. 2a) obserwujemy szybką zbieżność do optimum - już dla $T = 10$ osiągamy dokładność 0,997, a dla $T = 50$ wynosi ona 1,000.
- Na zbiorze Breast Cancer (rys. 2b) zwiększanie T powoduje stopniowy wzrost dokładności (z 0,960 dla $T = 10$ do 0,966 dla $T = 100$) oraz zmniejszenie odchylenia standardowego.
- Na zbiorze Wine Quality (rys. 2c) zwiększanie liczby estymatorów poprawia dokładność (z 0,718 dla $T = 10$ do 0,744 dla $T = 100$) oraz zmniejsza wariancję.
- Na zbiorze Car Evaluation (rys. 2d) dokładność jest stabilna i oscyluje wokół 0,813-0,815 niezależnie od liczby estymatorów, co sugeruje, że dodawanie kolejnych modeli nie wnosi nowej wiedzy w przypadku tego zbioru.
- Stabilizacja wyników następuje zazwyczaj w okolicy $T = 50$. Dalsze zwiększanie liczby estymatorów nie poprawia istotnie wyniku, a liniowo wydłuża czas obliczeń.

4.4 Scenariusz 3: Wpływ regularyzacji SVM (C)


Zbadano wpływ parametru $C \in \{0,1; 1; 10; 50\}$ dla części SVM (przy ustalonym $p_{svm} = 100\%$). W eksperymencie ustalono liczbę estymatorów $T = 50$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation


Rysunek 3: Wpływ parametru regularyzacji SVM (C) na średnią dokładność (dla $T = 50$ oraz $p_{svm} = 100\%$; wartości $C \in \{0,1; 1; 10; 50\}$).

Wnioski:

- Na zbiorze Mushroom (rys. 3a) dla $C \geq 10$ osiągamy perfekcyjną klasyfikację (1,00). Zbiór ten jest liniowo separowalny, więc większe C pozwala na dokładniejsze dopasowanie hiperpłaszczyzny.
- Na zbiorze Breast Cancer (rys. 3b) zwiększanie C poprawia wyniki - od 0,952 dla $C = 0,1$ do 0,963 dla $C = 50$. Wzrost jest stopniowy, co sugeruje dobrą separowalność liniową.
- Na zbiorach Wine Quality (rys. 3c) oraz Car Evaluation (rys. 3d) wpływ parametru C jest zauważalny, ale wyniki nadal pozostają na niższym poziomie (odpowiednio ok. 0,717 i 0,794). Wynika to z faktu, że liniowy SVM nie jest w stanie dobrze zamodelować nieliniowych zależności w tych zbiorach, niezależnie od wartości regularyzacji.
- Ogólnie, zbyt małe C (silna regularyzacja) może powodować niedopasowanie, natomiast dla zbiorów nieliniowych zwiększanie C nie przynosi istotnych korzyści.

4.5 Analiza błędów - Macierze Pomyłek (Heatmapy)

Poniżej przedstawiono zagregowane macierze pomyłek (suma z 25 uruchomień) dla modelu hybrydowego ($T = 50$, $p_{svm} = 50\%$, $C = 10,0$). Pozwala to ocenić, które klasy są mylone najczęściej.




Rysunek 4: Zagregowane macierze pomyłek (heatmapy) dla $T = 50$, $p_{svm} = 50\%$, $C = 10,0$.

Wnioski:

- Na zbiorze Mushroom (rys. 4a) klasyfikacja jest niemal perfekcyjna. Obserwowane nieliczne błędy mają charakter marginalny i mogą wynikać z losowego doboru podzbioru cech w poszczególnych estymatorach, nie wskazując na systematyczny problem modelu.
- Na zbiorze Breast Cancer (rys. 4b) model wykazuje wysoką skuteczność. Rozkład błędów fałszywie pozytywnych i fałszywie negatywnych jest zrównoważony, z lekką przewagą FP, co w zastosowaniach medycznych jest bezpieczniejszą tendencją (lepiej podejrzewać chorobę niż ją przeoczyć).
- Na zbiorze Wine Quality (rys. 4c) rozkład błędów jest bardziej zrównoważony. Model popełnia 6 056 błędów typu FP (low quality sklasyfikowane jako high quality) oraz 4 237 błędów typu FN (high quality sklasyfikowane jako low quality). Większa liczba FP może wynikać z tendencji modelu do klasyfikowania granicznych przypadków jako wyższą jakość.
- Na zbiorze Car Evaluation (rys. 4d) najczęściej mylone są klasy “unacc” i “good” (4732 błędów) oraz “vgood” klasyfikowana jako “unacc” (1321 błędów). Klasy rzadkie (“acc”, “vgood”) są bardzo słabo rozpoznawane - tylko 4 z 1725 przypadków “acc” i 166 z 1625 przypadków “vgood” zostało poprawnie sklasyfikowanych. Potwierdza to, że hybrydyzacja z liniowym SVM, bez wsparcia znacznym preprocesingiem danych, nie radzi sobie z niebalansowanymi, wieloklasowymi zbiorami.

4.6 Analiza nadmiernego dopasowania (Overfitting)

W celu oceny zjawiska przeuczenia porównano dokładność na zbiorze treningowym i testowym dla modelu hybrydowego ($T = 50$, $p_{svm} = 50\%$, $C = 10,0$).



Rysunek 5: Porównanie dokładności na zbiorze treningowym i testowym (Train vs Test) dla $T = 50$, $p_{svm} = 50\%$, $C = 10,0$.

Wnioski:

- Na zbiorze Mushroom (rys. 5a) przeuczenie nie występuje ($\Delta \approx 0$). Model idealnie generalizuje.
- Na zbiorze Breast Cancer (rys. 5b) różnica między zbiorem treningowym a testowym wynosi około 2,3 p.p., co jest wartością niską i akceptowalną.
- Na zbiorach Wine Quality oraz Car Evaluation różnice wynoszą odpowiednio ok. 3,9 p.p. i 3,7 p.p. Jest to umiarkowany poziom przeuczenia, typowy dla metod zespołowych na trudniejszych zbiorach danych.
- Ogólnie, model hybrydowy wykazał dobrą zdolność do generalizacji, z umiarkowanym przeuczeniem na bardziej złożonych zbiorach danych.

5 Podsumowanie i wnioski końcowe

Zrealizowany projekt pozwolił na zbadanie właściwości hybrydowego lasu klasyfikacyjnego łączącego drzewa ID3 z klasyfikatorami SVM.

- Uzyskane optymalne parametry modelu hybrydowego to: liczba estymatorów $T = 50$, udział SVM $p_{svm} = 50\%$, regularyzacja SVM $C = 10,0$.

1. Czego się nauczyliśmy:

- Jak dobór klasyfikatora bazowego zależy od charakteru danych: SVM (liniowy) preferuje zbiory (w przybliżeniu) liniowo separowalne, natomiast ID3 lepiej radzi sobie z nieliniowymi zależnościami oraz danymi kategorycznymi.
- Eksperyment na zbiorze *Synthetic Diagonal* potwierdził przewagę liniowego SVM w problemach z ukośną, liniową granicą decyzyjną, gdzie klasyczne, drzewa decyzyjne mają trudności z aproksymacją funkcji.
- Jak istotna jest różnorodność estymatorów w zespole: zastosowanie *Random Subspace Method* (domyślnie $m = \sqrt{M}$) okazało się kluczowe, aby modele w lesie podejmowały odmienne decyzje i żeby głosowanie miało sens.
- Jak interpretować wyniki eksperymentów: analiza wariancji (odchylenia standardowego) oraz macierzy pomyłek pozwala lepiej ocenić zachowanie, efektywność modelu niż sama dokładność.