

Dokumentacja końcowa projektu UMA

Jan Szwagierczak, Tomasz Okoń

9 stycznia 2026

1 Treść zadania

„Połączenie lasu losowego z SVM w zadaniu klasyfikacji. Postępujemy tak jak przy tworzeniu lasu losowego, tylko pewien procent klasyfikatorów w lesie to SVM. Jeden z klasyfikatorów (SVM lub drzewo ID3) może pochodzić z istniejącej implementacji.”

2 Algorytmy i struktura rozwiązania

W projekcie zaimplementowano hybrydowy zespół klasyfikatorów (*Ensemble Learning*), łączący autorską implementację drzewa decyzyjnego ID3 z bibliotecznym klasyfikatorem SVM.

2.1 Autorskie drzewo ID3

Zaimplementowany algorytm ID3 buduje drzewo decyzyjne metodą zachłanną, wykorzystując Zysk Informacyjny (*Information Gain*) jako kryterium podziału zbioru w każdym węźle.

Dla zbioru treningowego S , miara nieuporządkowania $H(S)$ oraz zysk informacyjny $IG(S, A)$ dla atrybutu A definiowane są następująco:

$$H(S) = - \sum_{i=1}^k p_i \log_2(p_i), \quad IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

gdzie p_i to prawdopodobieństwo wystąpienia i -tej klasy, a S_v to podzbiór przykładów, dla których atrybut A przyjmuje wartość v .

Procedura budowy drzewa jest rekurencyjna: w każdym kroku wybierany jest atrybut maksymalizujący IG , a zbiór dzielony jest na podzbiory, aż do uzyskania jednorodności klas w liściach lub wyczerpania atrybutów.

2.2 Support Vector Machine (SVM)

Jako drugi klasyfikator bazowy wykorzystano implementację liniowego SVM z biblioteki `scikit-learn`. Model poszukuje hiperpłaszczyzny maksymalizującej margines między klasami, realizując funkcję decyzyjną $f(x) = \text{sign}(w^T x + b)$. Proces uczenia polega na minimalizacji funkcji kosztu:

$$\frac{1}{2} \|w\|^2 + C \sum_i \xi_i,$$

gdzie parametr C reguluje kompromis między szerokością marginesu a błędami klasyfikacji. Dla problemów wieloklasowych zastosowano strategię *One-vs-Rest*.

2.3 Algorytm Lasu Hybrydowego

Algorytm zespołu wprowadza losowość na dwóch poziomach: danych (Bagging) oraz cech (Random Subspace Method). Procedura uczenia dla T estymatorów przebiega następująco:

1. Dla każdego estymatora $i = 1 \dots T$:

- Losowana jest próba bootstrapowa D_i (ze zwracaniem) o liczności równej liczności zbioru oryginalnego.
 - Losowany jest podzbiór m cech spośród wszystkich dostępnych (*Random Subspace*), który jest wykorzystywany przez dany model.
 - Z prawdopodobieństwem p_{svm} trenowany jest klasyfikator SVM (na danych ciągłych/One-Hot), w przeciwnym razie $(1 - p_{svm})$ budowane jest drzewo ID3 (na danych dyskretnych).
2. Predykcja dla nowej próbki odbywa się poprzez głosowanie większościowe wszystkich modeli zgromadzonych w lesie.

2.4 Odstępstwa i doprecyzowanie implementacji

W stosunku do pierwotnych założeń wprowadzono istotne doprecyzowania wynikające z fazy implementacji:

- **Random Subspace Method:** Aby zapewnić różnorodność klasyfikatorów, wprowadzono losowanie podzbioru cech dla każdego estymatora. Wartość m (liczba cech używanych przez pojedynczy klasyfikator) domyślnie ustawiono na \sqrt{M} (gdzie M to liczba cech), z dynamicznym dostosowaniem dla zbiorów o bardzo małej liczbie atrybutów.
- **Obsługa danych heterogenicznych:** Las obsługuje jednocześnie dwie reprezentacje danych: dyskretną (dla ID3) oraz ciągłą/zakodowaną One-Hot (dla SVM), przekazując do konkretnego estymatora odpowiedni format danych wejściowych.

2.5 Weryfikacja poprawności (Testy)

Aby upewnić się, że implementacja nie zawiera błędów, przeprowadzono:

1. **Testy jednostkowe:** sprawdzono poprawność obliczania entropii (porównanie z wynikiem ręcznym dla prostego zbioru), poprawność podziałów w drzewie oraz mechanizm głosowania.
2. **Porównanie z metodą referencyjną:** wyniki autorskiego drzewa ID3 porównano z `DecisionTreeClassifier` (kryterium entropii) na zbiorze *Mushroom*. Uzyskano zgodność wyników (dokładność $\approx 100\%$), co potwierdza poprawność logiki budowy drzewa.

3 Metodyka badań

3.1 Zbiory danych

Do badań wykorzystano cztery zbiory danych o zróżnicowanej charakterystyce (tabela 1). Zbiór *Mushroom* pełni funkcję weryfikacyjną. Zbiory ciągłe (*Breast Cancer*, *Wine*) zostały poddane dyskretyzacji dla algorytmu ID3 (metoda kubelkowa), natomiast zbiory dyskretne (*Mushroom*, *Car Evaluation*) zostały zakodowane metodą One-Hot Encoding na potrzeby klasyfikatora SVM.

Tabela 1: Charakterystyka zbiorów danych

Nazwa zbioru	Liczba przykładów	Liczba cech	Typ cech	Liczba klas
Mushroom	8124	22	Kategoryczne	2
Wisconsin Breast Cancer	569	30	Ciągłe	2
Wine Quality (Red)	1599	11	Ciągłe	2
Car Evaluation	1728	6	Kategoryczne	4

Szczegółowy rozkład klas w zbiorach:

- **Mushroom:** 4208 (edible), 3916 (poisonous) – zbiór zbalansowany.

- **Wisconsin Breast Cancer:** 357 (benign), 212 (malignant) – zbiór lekko niezbilansowany.
- **Wine Quality (Red):** 744 (low quality), 855 (high quality) – zbiór lekko niezbilansowany. Zastosowano binaryzację etykiet, przyjmując próg jakości `quality` ≥ 6 jako klasę pozytywną.
- **Car Evaluation:** 1210 (unacc), 384 (acc), 69 (good), 65 (vgood) – zbiór silnie niezbilansowany.

3.2 Procedura eksperymentalna

Każdy eksperyment przeprowadzono zgodnie z poniższymi zasadami, aby zapewnić rzetelność i powtarzalność wyników:

- **Weryfikacja poprawności:** Przed przystąpieniem do głównych eksperymentów wykonano testy jednostkowe oraz porównano wyniki autorskiej implementacji z metodami referencyjnymi (biblioteka `scikit-learn`).
- **Wielokrotne uruchomienia:** Każdy punkt pomiarowy stanowi średnią z 25 niezależnych uruchomień algorytmu. W każdej iteracji stosowano inne ziarno losowości (`random_state`) wpływające na podział zbioru, bootstrap oraz dobór cech.
- **Podział danych:** Zastosowano 5-krotną walidację krzyżową (5-fold Stratified CV), co w połączeniu z 25 powtórzeniami daje łącznie 125 prób trenowania dla każdej konfiguracji parametrów.
- **Miary jakości:** Raportowana jest średnia dokładność (Accuracy), odchylenie standardowe, wynik minimalny i maksymalny oraz zagregowane macierze pomyłek (sumowane ze wszystkich uruchomień).

4 Wyniki eksperymentów

4.1 Weryfikacja

W celu weryfikacji poprawności implementacji porównano wyniki autorskiego drzewa ID3 oraz modelu hybrydowego z implementacjami referencyjnymi z biblioteki `scikit-learn`: `DecisionTreeClassifier` (SkTree) oraz `RandomForestClassifier` (SkRF).

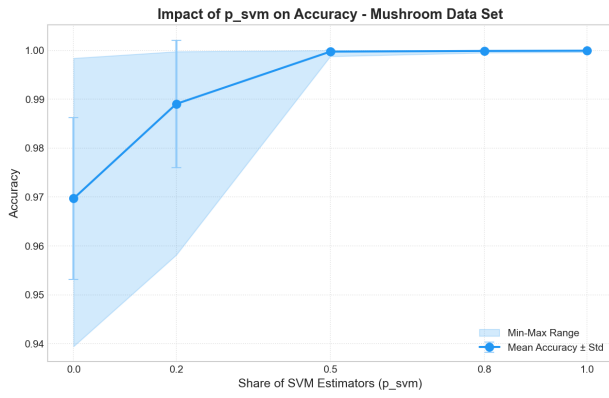
Tabela 2: Porównanie dokładności implementacji autorskich z referencyjnymi

Zbiór danych	ID3	SkTree	Hybrid	SkRF	H-RF	Diff
Mushroom	1,0000	1,0000	0,9996	1,0000	–0,0004	
Breast Cancer	0,9240	0,9240	0,9532	0,9415	+0,0117	
Wine Quality	0,7458	0,7542	0,7250	0,7812	–0,0563	
Car Evaluation	0,9383	0,9750	0,7784	0,9692	–0,1908	


Wnioski: Autorska implementacja ID3 osiąga identyczne wyniki jak `DecisionTreeClassifier` na zbiorze Mushroom (1,0000) oraz Breast Cancer (0,9240), co potwierdza poprawność algorytmu. Model hybrydowy przewyższa las losowy na zbiorze Breast Cancer (+1,17 p.p.), natomiast na zbiorach z cechami kategorycznymi (Car Evaluation) oraz wieloklasowych ustępuje implementacji referencyjnej – co jest zgodne z oczekiwaniami dla liniowego SVM. Na zbiorze Wine Quality model hybrydowy (0,725) ustępuje referencyjnemu lasowi losowemu (0,781) o 5,6 p.p.

4.2 Scenariusz 1: Wpływ udziału SVM w lesie (p_{svm})


Zbadano wpływ parametru $p_{svm} \in \{0,20,50,80,100\}\%$. Parametr ten determinuje, jak duża część lasu składa się z klasyfikatorów SVM (reszta to ID3). W eksperymencie ustalono liczbę estymatorów $T = 20$ oraz parametr regularyzacji SVM $C = 1,0$.



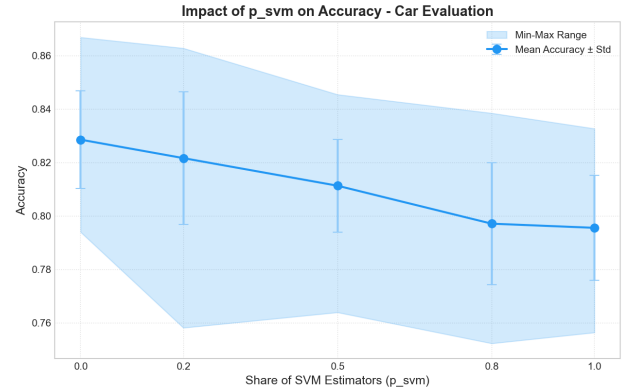
(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation

Rysunek 1: Średnia dokładność w zależności od udziału SVM (p_{svm}) dla $T = 20$ oraz $C = 1,0$. Słupki błędów oznaczają odchylenie standardowe.

Tabela 3: Szczegółowe wyniki dla zbioru **Wisconsin Breast Cancer** (średnia z 25 uruchomień)

p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,945	0,006	0,938	0,958
20	0,954	0,005	0,942	0,965
50	0,960	0,005	0,949	0,968
80	0,959	0,002	0,954	0,963
100 (Czyste SVM)	0,957	0,004	0,951	0,963

Tabela 4: Szczegółowe wyniki dla zbioru **Wine Quality** (średnia z 25 uruchomień)

p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,744	0,010	0,724	0,767
20	0,740	0,012	0,721	0,760
50	0,728	0,014	0,698	0,750
80	0,716	0,017	0,670	0,743
100 (Czyste SVM)	0,708	0,016	0,662	0,734


Wnioski:

- Na zbiorze Mushroom (rys. 1a) obserwujemy odwrotny trend niż na pozostałych zbiorach – zwiększanie udziału SVM poprawia wyniki. Dla czystego ID3 ($p_{svm} = 0\%$) dokładność wynosi jedynie 0,970, podczas gdy dla czystego SVM ($p_{svm} = 100\%$) osiągamy 0,9999. Zbiór ten jest liniowo separowalny, co stanowi idealne środowisko dla SVM.


- Na zbiorze Breast Cancer (tab. 3, rys. 1b) hybrydyzacja przyniosła najlepsze rezultaty. Optimum osiągnięto dla $p_{svm} = 50\%$ (dokładność 0,960), co jest wynikiem wyższym niż dla czystego ID3 (0,945) oraz czystego SVM (0,957). Wskazuje to, że ensemble korzysta z różnorodności błędów popełnianych przez drzewa (nieliniowe granice decyzyjne) i SVM (liniowe granice).
- Na zbiorze Wine Quality (tab. 4, rys. 1c) obserwujemy tendencję spadkową – najlepsze wyniki uzyskano dla czystego ID3 ($p_{svm} = 0\%$, dokładność 0,744), a zwiększanie udziału SVM stopniowo pogarszało jakość klasyfikacji (spadek do 0,708 dla $p_{svm} = 100\%$). Liniowy SVM ma trudności z separacją klas w przestrzeni cech ciągłych po dyskretyzacji.
- Na zbiorze Car Evaluation (rys. 1d) odnotowano podobny trend jak dla Wine Quality – spadek jakości wraz ze wzrostem udziału SVM (z 0,829 dla ID3 do 0,796 dla SVM). Relacje w tym zbiorze są silnie nieliniowe i kategoryczne, co jest naturalnym środowiskiem dla drzew decyzyjnych.

4.3 Scenariusz 2: Wpływ liczby estymatorów (T)


Zbadano wpływ rozmiaru lasu $T \in \{10, 20, 50, 100\}$ na stabilność i jakość predykcji. W eksperymencie ustalono udział SVM na $p_{svm} = 50\%$ oraz regularyzację $C = 1,0$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation

Rysunek 2: Wpływ liczby estymatorów (T) na średnią dokładność dla różnych zbiorów danych (dla $p_{svm} = 50\%$ oraz $C = 1,0$).


Wnioski:

- Na zbiorze Mushroom (rys. 2a) obserwujemy szybką zbieżność do optimum – już dla $T = 10$ osiągamy dokładność 0,997, a dla $T = 20$ wynosi ona 0,9997. Dalsze zwiększanie liczby estymatorów nie przynosi istotnej poprawy (0,9999 dla $T = 50$ i $T = 100$).
- Na zbiorze Breast Cancer (rys. 2b) zwiększanie T powoduje stopniowy wzrost dokładności (z 0,958 dla $T = 10$ do 0,961 dla $T = 100$) oraz zmniejszenie odchylenia standardowego (z 0,007 do 0,003), co potwierdza teorię redukcji wariancji w ensemble learning.


- Na zbiorze Wine Quality (rys. 2c) zwiększanie liczby estymatorów poprawia dokładność (z 0,717 dla $T = 10$ do 0,744 dla $T = 100$) oraz zmniejsza wariancję (odchylenie standardowe spada z 0,015 do 0,008). Na zbiorze Car Evaluation (rys. 2d) dokładność stabilizuje się na poziomie 0,812, a odchylenie standardowe spada z 0,017 do 0,010.
- Stabilizacja wyników następuje w okolicy $T = 50$. Dalsze zwiększanie liczby estymatorów nie poprawia istotnie wyniku, a liniowo wydłuża czas obliczeń.

4.4 Scenariusz 3: Wpływ regularyzacji SVM (C)


Zbadano wpływ parametru $C \in \{0,1; 1; 10; 50\}$ dla części SVM (przy ustalonym $p_{sum} = 100\%$). W eksperymencie ustalono liczbę estymatorów $T = 20$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation

Rysunek 3: Wpływ parametru regularyzacji SVM (C) na średnią dokładność (dla $T = 20$ oraz $p_{sum} = 100\%$; wartości $C \in \{0,1; 1; 10; 50\}$).

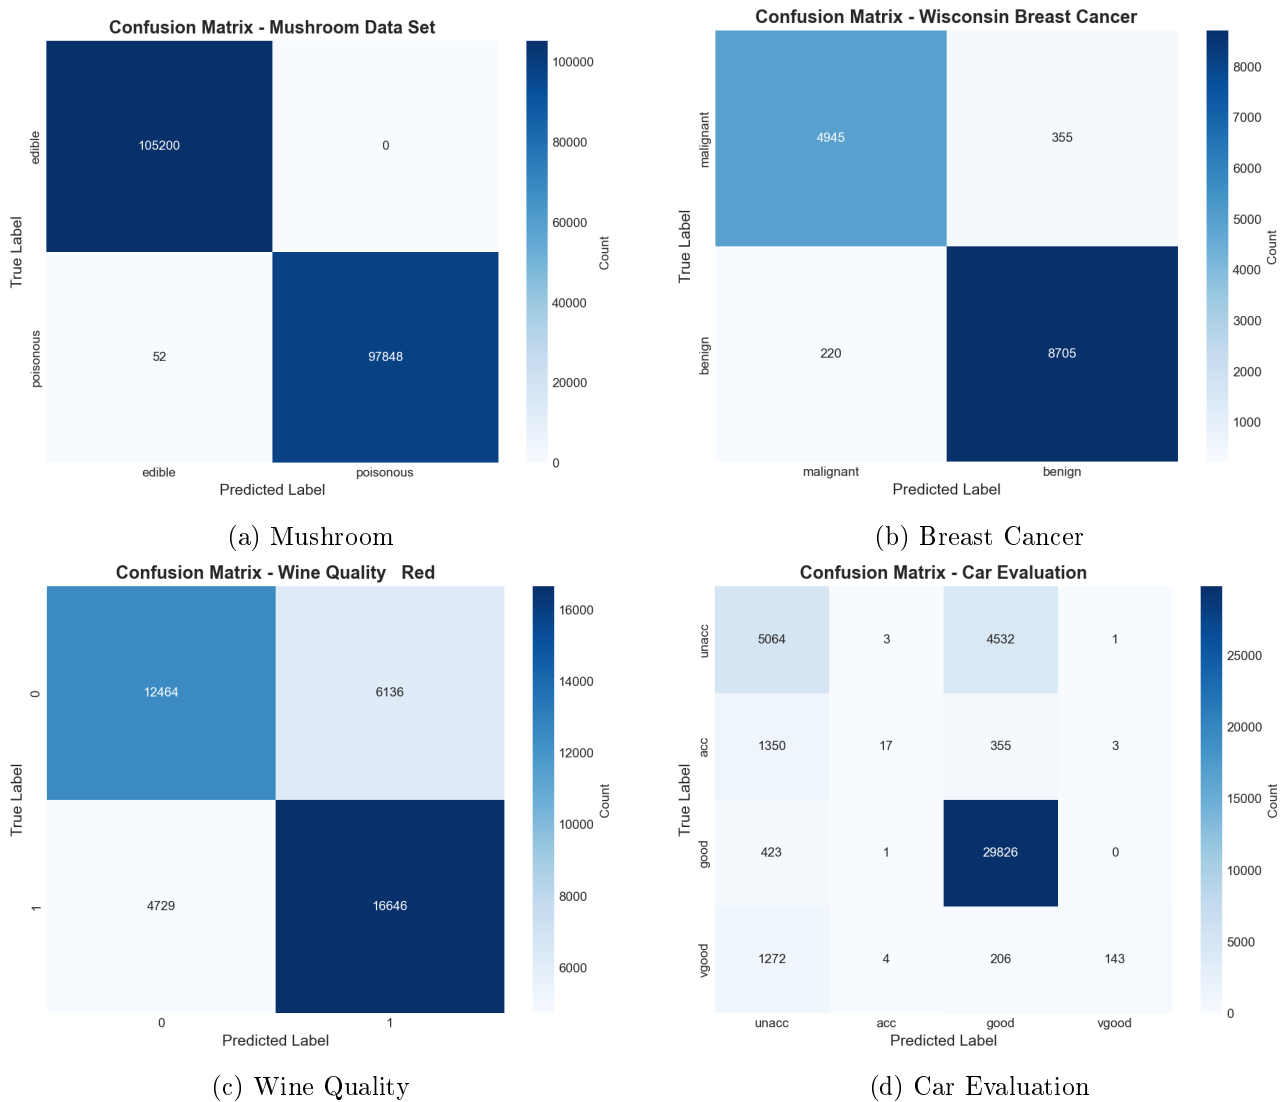
Wnioski:

- Na zbiorze Mushroom (rys. 3a) obserwujemy wyraźny wpływ parametru C – dla $C = 0,1$ dokładność wynosi 0,999, natomiast dla $C \geq 10$ osiągamy perfekcyjną klasyfikację (1,000). Zbiór ten jest liniowo separowalny, więc większe C pozwala na dokładniejsze dopasowanie hiperpłaszczyzny.
- Na zbiorze Breast Cancer (rys. 3b) zwiększanie C poprawia wyniki – od 0,952 dla $C = 0,1$ do 0,963 dla $C = 50$. Wzrost jest stopniowy i stabilny, co sugeruje, że dane są dobrze separowalne liniowo, a słaba regularyzacja (wysokie C) nie prowadzi do przeuczenia.
- Na zbiorach Wine Quality (rys. 3c) oraz Car Evaluation (rys. 3d) wpływ parametru C jest minimalny – dokładność zmienia się odpowiednio w zakresie 0,703–0,710 oraz 0,791–0,796. Wynika to z faktu, że liniowy SVM nie jest w stanie dobrze zamodelować nieliniowych zależności w tych zbiorach, niezależnie od wartości regularyzacji.

- Ogólnie, zbyt małe C (silna regularyzacja) powoduje niedopasowanie modelu, natomiast dla zbiorów nieliniowych zwiększanie C nie przynosi istotnych korzyści.

4.5 Analiza błędów - Macierze Pomyłek (Heatmapy)

Poniżej przedstawiono zagregowane macierze pomyłek (suma z 25 uruchomień) dla modelu hybrydowego ($T = 20$, $p_{svm} = 50\%$, $C = 1,0$). Pozwala to ocenić, które klasy są mylone najczęściej.



Rysunek 4: Zagregowane macierze pomyłek (heatmapy) dla $T = 20$, $p_{svm} = 50\%$, $C = 1,0$.

Wnioski:

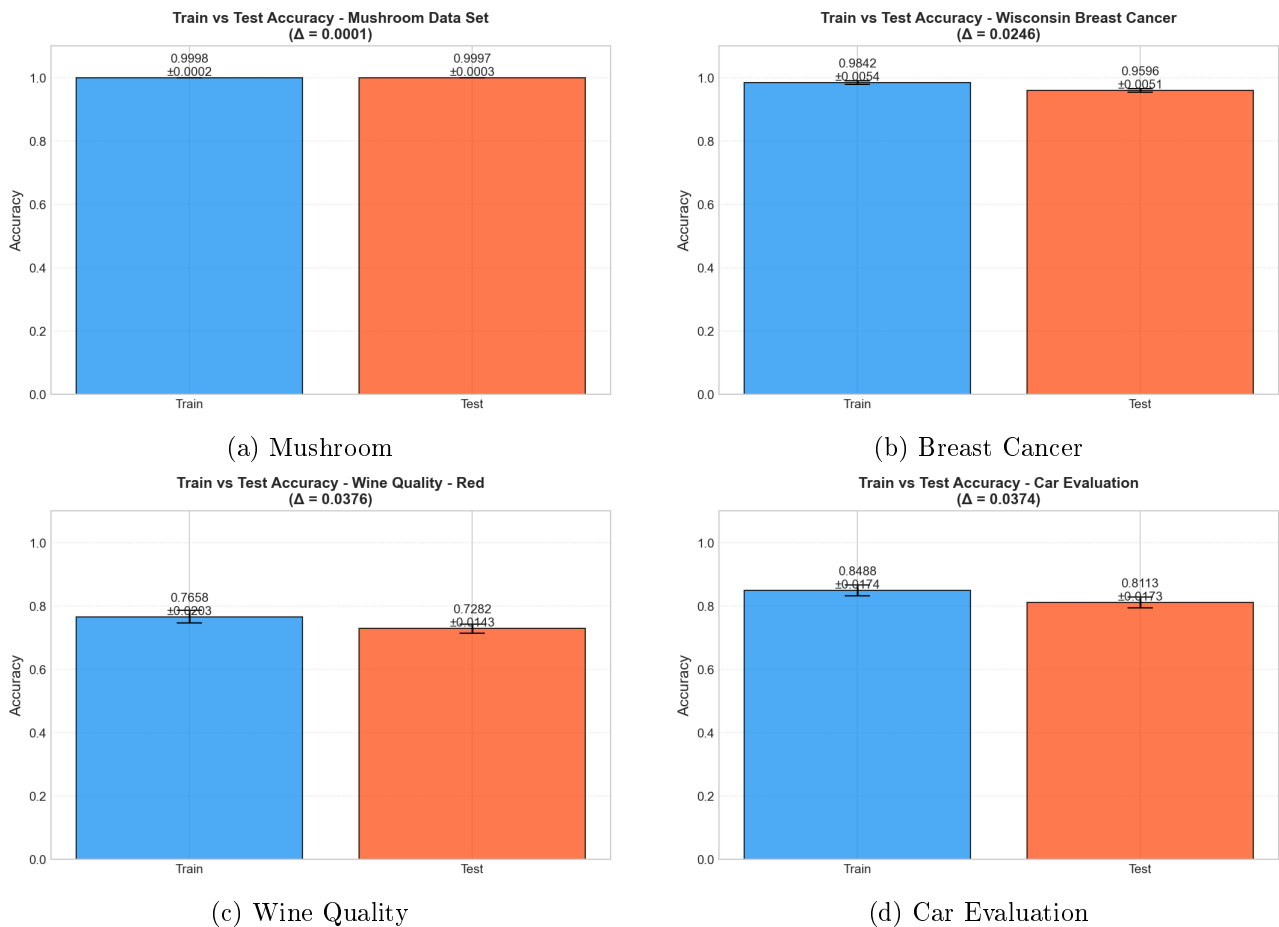
- Na zbiorze Mushroom (rys. 4a) obserwujemy niemal perfekcyjną klasyfikację – tylko 52 błędy na ponad 200 000 predykcji (zagregowanych z 25 uruchomień). Co ciekawe, błędy są jednostronne (tylko False Negative), co oznacza, że model sporadycznie klasyfikuje grzyby trujące jako jadalne, ale nigdy odwrotnie (w badanej próbie).
- Na zbiorze Breast Cancer (rys. 4b) model popełnia więcej błędów typu FP (355 przypadków benign sklasyfikowanych jako malignant) niż FN (220 przypadków malignant sklasyfikowanych jako benign). W kontekście diagnostyki medycznej taki rozkład błędów jest akceptowalny – lepiej fałszywie zaalarmować niż przeoczyć chorobę.
- Na zbiorze Wine Quality (rys. 4c) rozkład błędów jest bardziej zrównoważony. Model popełnia 6 136 błędów typu FP (low quality sklasyfikowane jako high quality) oraz 4 729 błędów typu FN

(high quality sklasyfikowane jako low quality). Większa liczba FP wynika z tendencji modelu do klasyfikowania granicznych przypadków jako wyższą jakość.

- Na zbiorze Car Evaluation (rys. 4d) najczęściej mylone są klasy “unacc” i “good” (4532 błędów) oraz “vgood” klasyfikowana jako “unacc” (1272 błędów). Klasy rzadkie (“acc”, “vgood”) są bardzo słabo rozpoznawane – tylko 17 z 1725 przypadków “acc” i 143 z 1625 przypadków “vgood” zostało poprawnie sklasyfikowanych. Potwierdza to, że hybrydyzacja z liniowym SVM nie rozwiązuje problemu niezbalansowanych zbiorów wieloklasowych.

4.6 Analiza nadmiernego dopasowania (Overfitting)

W celu oceny zjawiska przeuczenia porównano dokładność na zbiorze treningowym i testowym dla modelu hybrydowego ($T = 20$, $p_{svm} = 50\%$, $C = 1,0$).



Rysunek 5: Porównanie dokładności na zbiorze treningowym i testowym (Train vs Test) dla $T = 20$, $p_{svm} = 50\%$, $C = 1,0$.

Wnioski:

- Na zbiorze Mushroom (rys. 5a) nie obserwujemy przeuczenia – dokładność treningowa (0,9998) i testowa (0,9997) są niemal identyczne (różnica $\Delta = 0,008$ p.p.). Zbiór jest łatwy do klasyfikacji i model dobrze generalizuje.
- Na zbiorze Breast Cancer (rys. 5b) występuje umiarkowane przeuczenie – dokładność treningowa wynosi 0,984, a testowa 0,960 (różnica $\Delta = 2,46$ p.p.). Jest to akceptowalny poziom, wskazujący na dobrą generalizację modelu.
- Na zbiorze Wine Quality (rys. 5c) występuje umiarkowane przeuczenie – dokładność treningowa wynosi 0,766, a testowa 0,728 (różnica $\Delta = 3,76$ p.p.). Wynik jest porównywalny z innymi zbiorami i wskazuje na typowe zachowanie modelu ensemble.

- Na zbiorze Car Evaluation (rys. 5d) obserwujemy wyraźne przeuczenie – dokładność treningowa wynosi 0,849, a testowa 0,811 (różnica $\Delta = 3,74$ p.p.). Drzewa ID3 mają tendencję do budowania głębokich struktur bez przycinania, co prowadzi do nadmiernego dopasowania do danych treningowych.
- Ogólnie, zastosowanie techniki Bagging (losowanie próbek bootstrapowych) zmniejsza efekt przeuczenia w porównaniu do pojedynczego drzewa decyzyjnego. Dalszą poprawę można uzyskać przez wprowadzenie ograniczenia głębokości drzewa (`max_depth`).

5 Podsumowanie i wnioski końcowe

Zrealizowany projekt pozwolił na zbadanie właściwości hybrydowego lasu klasyfikacyjnego łączącego drzewa ID3 z klasyfikatorami SVM. Główne wnioski z badań są następujące:

1. Skuteczność hybrydyzacji zależy od charakterystyki danych:

- Na zbiorze Mushroom (cechy kategoryczne, liniowo separowalny) najlepsze wyniki uzyskano dla czystego SVM ($p_{svm} = 100\%$, dokładność 0,9999), podczas gdy czyste ID3 osiągało jedynie 0,970.
- Na zbiorze Breast Cancer (cechy ciągłe, częściowo separowalne liniowo) hybrydyzacja przyniosła najlepsze rezultaty – optimum dla $p_{svm} = 50\%$ (dokładność 0,960) przewyższyło zarówno czyste ID3 (0,945), jak i czyste SVM (0,957).
- Na zbiorach z cechami kategorycznymi i nieliniowymi zależnościami (Car Evaluation) oraz Wine Quality dodanie SVM pogarszało wyniki – spadek dokładności odpowiednio z 0,829 do 0,796 oraz z 0,744 do 0,708 przy wzroście p_{svm} od 0% do 100%.

2. Poprawność implementacji: Autorska implementacja ID3 osiąga identyczne wyniki jak `DecisionTreeClassifier` ze `scikit-learn` na zbiorach Mushroom (1,000) i Breast Cancer (0,924), co potwierdza poprawność algorytmu.

3. Wpływ hiperparametrów:

- Liczba estymatorów T : stabilizacja wyników następuje przy $T \approx 50$, dalsze zwiększanie redukuje wariancję, ale nie poprawia dokładności.
- Parametr regularyzacji C : istotny tylko dla zbiorów liniowo separowalnych (Mushroom, Breast Cancer); dla zbiorów nieliniowych (Wine, Car) wpływ minimalny.

4. Ograniczenia podejścia:

- Liniowy SVM nie radzi sobie z silnie niezbalansowanymi zbiorami wieloklasowymi – na zbiorze Car Evaluation klasy rzadkie (acc, vgood) były niemal całkowicie ignorowane.
- Drzewa ID3 bez przycinania wykazują tendencję do przeuczenia (różnica train-test do 3,76 p.p. na zbiorach Wine Quality i Car Evaluation).

5. Czego się nauczyliśmy: Realizacja projektu pozwoliła zrozumieć praktyczne różnice między modelami generatywnymi (drzewa) a dyskryminacyjnymi (SVM). Kluczowa dla algorytmów zespołowych okazała się różnorodność estymatorów bazowych – wprowadzenie Random Subspace Method ($m = \sqrt{M}$ cech) było niezbędne dla uzyskania korzyści z hybrydyzacji.