

Dokumentacja końcowa projektu UMA

Jan Szwagierczak, Tomasz Okoń

23 stycznia 2026

1 Treść zadania

„Połączenie lasu losowego z SVM w zadaniu klasyfikacji. Postępujemy tak jak przy tworzeniu lasu losowego, tylko pewien procent klasyfikatorów w lesie to SVM. Jeden z klasyfikatorów (SVM lub drzewo ID3) może pochodzić z istniejącej implementacji.”

2 Algorytmy i struktura rozwiązania

W projekcie zaimplementowano hybrydowy zespół klasyfikatorów, łączący autorską implementację drzewa decyzyjnego ID3 z bibliotecznym klasyfikatorem SVM.

2.1 Autorskie drzewo ID3

Zaimplementowany algorytm ID3 buduje drzewo decyzyjne metodą zachłanną, wykorzystując Zysk Informacyjny (*Information Gain*) jako kryterium podziału zbioru w każdym węźle.

Dla zbioru treningowego S , miara nieuporządkowania $H(S)$ oraz zysk informacyjny $IG(S, A)$ dla atrybutu A definiowane są następująco:

$$H(S) = - \sum_{i=1}^k p_i \log_2(p_i), \quad IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

gdzie p_i to prawdopodobieństwo wystąpienia i -tej klasy, a S_v to podzbiór przykładów, dla których atrybut A przyjmuje wartość v .

Procedura budowy drzewa jest rekurencyjna: w każdym kroku wybierany jest atrybut z największym zyskiem informacyjnym, a zbiór dzielony jest na podzbiory, aż do uzyskania takich samych klas w liściach lub wyczerpania atrybutów.

2.2 Support Vector Machine (SVM)

Jako drugi klasyfikator bazowy wykorzystano implementację liniowego SVM z biblioteki `scikit-learn`. Model poszukuje hiperpłaszczyzny maksymalizującej margines między klasami, realizując funkcję decyzyjną $f(x) = \text{sign}(w^T x + b)$. Proces uczenia polega na minimalizacji funkcji:

$$\frac{1}{2} \|w\|^2 + C \sum_i \xi_i,$$

gdzie parametr C reguluje kompromis między marginesem a błędami klasyfikacji. Dla problemów wieloklasowych zastosowano strategię *One-vs-Rest*.

2.3 Algorytm Lasu

Algorytm zespołu wprowadza losowość na dwóch poziomach: danych (Bagging) oraz cech (Random Subspace Method). Procedura uczenia dla T estymatorów przebiega następująco:

1. Dla każdego estymatora $i = 1 \dots T$:

- Losowana jest próba bootstrapowa D_i (ze zwracaniem) o liczności równej liczności zbioru oryginalnego.
 - Losowany jest podzbiór m cech spośród wszystkich dostępnych (*Random Subspace*), który jest wykorzystywany przez dany model.
 - Z prawdopodobieństwem p_{svm} trenowany jest klasyfikator SVM (na danych ciągłych/One-Hot), w przeciwnym razie $(1 - p_{svm})$ budowane jest drzewo ID3 (na danych dyskretnych).
2. Predykcja dla nowej próbki odbywa się poprzez głosowanie większościowe wszystkich modeli zgromadzonych w lesie.

2.4 Odstępstwa i doprecyzowanie implementacji

W stosunku do pierwotnych założeń wprowadzono następujące doprecyzowania:

- **Random Subspace Method:** Aby zapewnić różnorodność klasyfikatorów, wprowadzono losowanie podzbioru cech dla każdego estymatora. Wartość m (liczba cech używanych przez pojedynczy klasyfikator) domyślnie ustawiono na $\sqrt{M}$ (gdzie M to liczba cech), z dynamicznym dostosowaniem dla zbiorów o bardzo małej liczbie atrybutów.
- **Obsługa danych heterogenicznych:** Las obsługuje jednocześnie dwie reprezentacje danych: dyskretną (dla ID3) oraz ciągłą/zakodowaną One-Hot (dla SVM), przekazując do konkretnego estymatora odpowiedni format danych wejściowych.
- **Syntetyczny zbiór danych:** Wygenerowano dodatkowy zbiór *Synthetic Diagonal*, w którym granica decyzyjna jest zdefiniowana jako hiperpłaszczyzna $\sum_{i=1}^{10} x_i = 5$. Zbiór ten został stworzony w celu wprowadzenia przykładu, gdzie liniowy SVM ma przewagę nad drzewami decyzyjnymi.

2.5 Weryfikacja poprawności (Testy)

Aby upewnić się, że implementacja nie zawiera błędów, przeprowadzono:

1. **Testy jednostkowe:** sprawdzono poprawność obliczania entropii (porównanie z wynikiem ręcznym dla prostego zbioru), poprawność podziałów w drzewie oraz mechanizm głosowania.
2. **Porównanie z metodą referencyjną:** wyniki autorskiego drzewa ID3 porównano z *DecisionTreeClassifier* na zbiorze *Mushroom*. Uzyskano zgodność wyników (dokładność $\approx 100\%$), co potwierdza poprawność logiki budowy drzewa.

3 Metodyka badań

3.1 Zbiory danych

Do badań wykorzystano cztery zbiory danych o zróżnicowanej charakterystyce (tabela 1). Zbiór *Mushroom* pełni funkcję weryfikacyjną. Zbiory ciągłe (*Breast Cancer*, *Wine*) zostały poddane dyskretyzacji dla algorytmu ID3 (metoda kubelkowa), natomiast zbiory dyskretne (*Mushroom*, *Car Evaluation*) zostały zakodowane metodą One-Hot Encoding na potrzeby klasyfikatora SVM.

Tabela 1: Charakterystyka zbiorów danych

Nazwa zbioru	Liczba przykładów	Liczba cech	Typ cech	Liczba klas
Mushroom	8124	22	Kategoryczne	2
Wisconsin Breast Cancer	569	30	Ciągłe	2
Wine Quality (Red)	1599	11	Ciągłe	2
Car Evaluation	1728	6	Kategoryczne	4
Synthetic Diagonal	925	10	Ciągłe	2

Szczegółowy rozkład klas w zbiorach:

- **Mushroom:** 4208 (edible), 3916 (poisonous) - zbiór zbalansowany.
- **Wisconsin Breast Cancer:** 357 (benign), 212 (malignant) - zbiór lekko niezbalansowany.
- **Wine Quality (Red):** 744 (low quality), 855 (high quality) - zbiór lekko niezbalansowany. Zastosowano binaryzację etykiet, przyjmując próg jakości $\text{quality} \geq 6$ jako klasę pozytywną.
- **Car Evaluation:** 1210 (unacc), 384 (acc), 69 (good), 65 (vgood) - zbiór silnie niezbalansowany.
- **Synthetic Diagonal:** Zbiór wygenerowany specjalnie do testów. Granica decyzyjna zdefiniowana jest jako hiperpłaszczyzna. Teoretycznie faworyzuje klasyfikatory liniowe (SVM), a jest trudny dla drzew decyzyjnych (problem aproksymacji schodkowej).

3.2 Procedura eksperymentalna

Każdy eksperyment przeprowadzono zgodnie z poniższymi zasadami, aby zapewnić rzetelność i powtarzalność wyników:

- **Wielokrotne uruchomienia:** Każdy pomiar stanowi średnią z 25 niezależnych uruchomień algorytmu. W każdej iteracji stosowano inne ziarno losowości (`random_state`).
- **Weryfikacja poprawności:** Przed przystąpieniem do głównych eksperymentów wykonano testy jednostkowe oraz porównano wyniki autorskiej implementacji z metodami referencyjnymi (biblioteka `scikit-learn`).
- **Podział danych:** Zastosowano 5-krotną walidację krzyżową, co w połączeniu z 25 powtórzeniami daje łącznie 125 prób trenowania dla każdej konfiguracji parametrów.
- **Miary jakości:** Raportowana jest średnia dokładność (Accuracy), odchylenie standardowe, wynik minimalny i maksymalny oraz zagregowane macierze pomyłek (sumowane ze wszystkich uruchomień).

4 Wyniki eksperymentów

4.1 Weryfikacja

W celu weryfikacji poprawności implementacji porównano wyniki autorskiego drzewa ID3 oraz modelu hybrydowego z implementacjami referencyjnymi z biblioteki `scikit-learn`. Odpowiednio:

- ID3 - autorska implementacja drzewa decyzyjnego,
- SkTree - `DecisionTreeClassifier` z biblioteki `scikit-learn`,
- RF - autorska implementacja lasu, parametry: liczba estymatorów $T = 50$, $p_{svm} = 0\%$ - czyli czysty las z drzew ID3,
- SkRF - `RandomForestClassifier` z biblioteki `scikit-learn`, parametry: liczba estymatorów $T = 50$, domyślne ustawienia pozostałych parametrów.
- Hybrid - autorska implementacja lasu, parametry optymalne: $T = 50$, $p_{svm} = 50\%$, $C = 10,0$,
- H-RF Diff - różnica dokładności między modelem hybrydowym a referencyjnym lasem losowym (Hybrid - RF).

Tabela 2: Porównanie dokładności implementacji autorskich z referencyjnymi

Zbiór danych	ID3	SkTree	RF	SkRF	Hybrid	H-RF Diff
Mushroom	0,9999	1,0000	0,9805	1,0000	0,9999	+0,0194
Breast Cancer	0,9265	0,9291	0,9497	0,9553	0,9644	+0,0147
Wine Quality	0,7382	0,7438	0,7550	0,7908	0,7427	-0,0123
Car Evaluation	0,9249	0,9771	0,8321	0,9800	0,8019	-0,0301
Synthetic Diagonal	0,6635	0,7498	0,8145	0,8719	0,9342	+0,1197

Wnioski:


Porównanie z metodami referencyjnymi wykazało poprawność implementacji autorskiego drzewa ID3 oraz lasu losowego (ID3 vs SkTree oraz RF vs SkRF), choć na trudniejszych zbiorach (Car Evaluation) autorski drzewo i las ustępuje optymalizowanej bibliotece Sklearn, ale wyniki ogólnie są zbliżone.

Model hybrydowy (Hybrid) osiąga najlepsze rezultaty na zbiorze *Wisconsin Breast Cancer* (dokładność 0,9644), przewyższając zarówno autorski las losowy (0,9497), jak i biblioteczny `RandomForestClassifier` (0,9553), co wskazuje na udaną synergię drzew i SVM w problemach medycznych o cechach ciągłych. Najbardziej spektakularną poprawę (+11,97 p.p.) uzyskano na zbiorze *Synthetic Diagonal*, co potwierdza hipotezę, że wprowadzenie liniowych estymatorów SVM pozwala lepiej modelować ukośne granice decyzyjne.


Na zbiorach o charakterystyce nieliniowej i kategorycznej (*Car Evaluation*) lub trudniejszej separowalności (*Wine Quality*), hybrydyzacja przyniosła pogorszenie wyników względem czystego lasu losowego (odpowiednio o 3,01 p.p. i 1,23 p.p.), co sugeruje, że wymuszanie liniowości w podprzestrzeniach cech jest tam niekorzystne.

4.2 Scenariusz 1: Wpływ udziału SVM w lesie (p_{svm})


Zbadano wpływ parametru $p_{svm} \in \{0,20,50,80,100\}\%$. Parametr ten określa, jak duża część lasu składa się z klasyfikatorów SVM (reszta to ID3). W eksperymencie ustalono liczbę estymatorów $T = 50$ oraz parametr regularyzacji SVM $C = 10,0$.




(a) Mushroom




(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation



(e) Synthetic Diagonal

Rysunek 1: Średnia dokładność w zależności od udziału SVM (p_{svm}) dla $T = 50$ oraz $C = 10,0$. Słupki błędów oznaczają odchylenie standardowe.

Tabela 3: Szczegółowe wyniki dla zbioru **Wisconsin Breast Cancer** (średnia z 25 uruchomień)

p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,948	0,005	0,939	0,958
20	0,958	0,005	0,949	0,968
50	0,965	0,004	0,958	0,972
80	0,963	0,003	0,958	0,968
100 (Czyste SVM)	0,962	0,003	0,954	0,967

Tabela 4: Szczegółowe wyniki dla zbioru **Wine Quality** (średnia z 25 uruchomień)


p_{svm} [%]	Średnia Dokładność	Odch. Std.	Min	Max
0 (Czyste ID3)	0,757	0,007	0,740	0,769
20	0,753	0,008	0,739	0,767
50	0,743	0,007	0,726	0,760
80	0,727	0,011	0,702	0,749
100 (Czyste SVM)	0,715	0,011	0,689	0,733

Wnioski:


- Na zbiorze Mushroom (rys. 1a) wyniki są zbliżone do 1,0, a obserwowane wahania mają charakter losowy. Oznacza to, że oba typy klasyfikatorów radzą sobie z tym problemem niemal bezbłędnie.
- Na zbiorze Synthetic Diagonal (rys. 1e) widoczna jest wyraźna przewaga SVM. Dokładność rośnie z 82,1% (dla czystego ID3) do 98,0% (dla czystego SVM). Wynika to z geometrii problemu – granica decyzyjna jest "ukośną" hiperpłaszczyzną, co jest prostsze do zamodelowania dla liniowego SVM.
- Na zbiorze Breast Cancer (tab. 3, rys. 1b) hybrydyzacja przyniosła najlepsze rezultaty. Optimum uzyskano dla $p_{svm} = 50\%$ (dokładność 0,965), co jest wynikiem wyższym niż dla czystego ID3 (0,948) oraz czystego SVM (0,962). Sugeruje to, że model hybrydowy skutecznie wykorzystuje różniące się własności zastosowanych klasyfikatorów: drzewo umożliwia modelowanie nieliniowych granic decyzyjnych, a SVM zapewnia liniową separację w przestrzeni cech.
- Na zbiorze Wine Quality (tab. 4, rys. 1c) obserwujemy tendencję spadkową - najlepsze wyniki uzyskano dla czystego ID3 ($p_{svm} = 0\%$, dokładność 0,757), a zwiększanie udziału SVM stopniowo pogarszało jakość klasyfikacji (spadek do 0,715 dla $p_{svm} = 100\%$). Sugeruje to, że relacje w tym zbiorze są nieliniowe i lepiej modelowane przez drzewa decyzyjne niż przez liniowy SVM.
- Na zbiorze Car Evaluation (rys. 1d) odnotowano podobny trend jak dla Wine Quality - spadek jakości wraz ze wzrostem udziału SVM (z 0,831 dla ID3 do 0,794 dla SVM). Relacje w tym zbiorze są silnie nieliniowe i kateryczne, co faworyzuje drzewa decyzyjne.

4.3 Scenariusz 2: Wpływ liczby estymatorów (T)


Zbadano wpływ rozmiaru lasu $T \in \{10, 20, 50, 100\}$ na stabilność i jakość predykcji. W eksperymencie ustalono udział SVM na $p_{svm} = 50\%$ oraz regularyzację $C = 10,0$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation


Rysunek 2: Wpływ liczby estymatorów (T) na średnią dokładność dla różnych zbiorów danych (dla $p_{svm} = 50\%$ oraz $C = 10,0$).

Wnioski:


- Na zbiorze Mushroom (rys. 2a) obserwujemy szybką zbieżność do optimum - już dla $T = 10$ osiągamy dokładność 0,997, a dla $T = 50$ wynosi ona 1,000.
- Na zbiorze Breast Cancer (rys. 2b) zwiększanie T powoduje stopniowy wzrost dokładności (z 0,960 dla $T = 10$ do 0,966 dla $T = 100$) oraz zmniejszenie odchylenia standardowego.
- Na zbiorze Wine Quality (rys. 2c) zwiększanie liczby estymatorów poprawia dokładność (z 0,718 dla $T = 10$ do 0,744 dla $T = 100$) oraz zmniejsza wariancję.
- Na zbiorze Car Evaluation (rys. 2d) dokładność jest stabilna i oscyluje wokół 0,813-0,815 niezależnie od liczby estymatorów, co sugeruje, że dodawanie kolejnych modeli nie wnosi nowej wiedzy w przypadku tego zbioru.
- Stabilizacja wyników następuje zazwyczaj w okolicy $T = 50$. Dalsze zwiększanie liczby estymatorów nie poprawia istotnie wyniku, a liniowo wydłuża czas obliczeń.

4.4 Scenariusz 3: Wpływ regularyzacji SVM (C)


Zbadano wpływ parametru $C \in \{0,1; 1; 10; 50\}$ dla części SVM (przy ustalonym $p_{svm} = 100\%$). W eksperymencie ustalono liczbę estymatorów $T = 50$.




(a) Mushroom



(b) Breast Cancer



(c) Wine Quality



(d) Car Evaluation


Rysunek 3: Wpływ parametru regularyzacji SVM (C) na średnią dokładność (dla $T = 50$ oraz $p_{svm} = 100\%$; wartości $C \in \{0,1; 1; 10; 50\}$).

Wnioski:

- Na zbiorze Mushroom (rys. 3a) dla $C \geq 10$ osiągamy perfekcyjną klasyfikację (1,00). Zbiór ten jest liniowo separowalny, więc większe C pozwala na dokładniejsze dopasowanie hiperpłaszczyzny.
- Na zbiorze Breast Cancer (rys. 3b) zwiększanie C poprawia wyniki - od 0,952 dla $C = 0,1$ do 0,963 dla $C = 50$. Wzrost jest stopniowy, co sugeruje dobrą separowalność liniową.
- Na zbiorach Wine Quality (rys. 3c) oraz Car Evaluation (rys. 3d) wpływ parametru C jest zauważalny, ale wyniki nadal pozostają na niższym poziomie (odpowiednio ok. 0,717 i 0,794). Wynika to z faktu, że liniowy SVM nie jest w stanie dobrze zamodelować nieliniowych zależności w tych zbiorach, niezależnie od wartości regularyzacji.
- Ogólnie, zbyt małe C (silna regularyzacja) może powodować niedopasowanie, natomiast dla zbiorów nieliniowych zwiększanie C nie przynosi istotnych korzyści.

4.5 Analiza błędów - Macierze Pomyłek (Heatmapy)

Poniżej przedstawiono zagregowane macierze pomyłek (suma z 25 uruchomień) dla modelu hybrydowego ($T = 50$, $p_{svm} = 50\%$, $C = 10,0$). Pozwala to ocenić, które klasy są mylone najczęściej.




Rysunek 4: Zagregowane macierze pomyłek (heatmapy) dla $T = 50$, $p_{svm} = 50\%$, $C = 10,0$.

Wnioski:

- Na zbiorze Mushroom (rys. 4a) klasyfikacja jest niemal perfekcyjna. Obserwowane nieliczne błędy mają charakter marginalny i mogą wynikać z losowego doboru podzbioru cech w poszczególnych estymatorach, nie wskazując na systematyczny problem modelu.
- Na zbiorze Breast Cancer (rys. 4b) model wykazuje wysoką skuteczność. Rozkład błędów fałszywie pozytywnych i fałszywie negatywnych jest zrównoważony, z lekką przewagą FP, co w zastosowaniach medycznych jest bezpieczniejszą tendencją (lepiej podejrzewać chorobę niż ją przeoczyć).
- Na zbiorze Wine Quality (rys. 4c) rozkład błędów jest bardziej zrównoważony. Model popełnia 6 056 błędów typu FP (low quality sklasyfikowane jako high quality) oraz 4 237 błędów typu FN (high quality sklasyfikowane jako low quality). Większa liczba FP może wynikać z tendencji modelu do klasyfikowania granicznych przypadków jako wyższą jakość.
- Na zbiorze Car Evaluation (rys. 4d) najczęściej mylone są klasy “unacc” i “good” (4732 błędów) oraz “vgood” klasyfikowana jako “unacc” (1321 błędów). Klasy rzadkie (“acc”, “vgood”) są bardzo słabo rozpoznawane - tylko 4 z 1725 przypadków “acc” i 166 z 1625 przypadków “vgood” zostało poprawnie sklasyfikowanych. Potwierdza to, że hybrydyzacja z liniowym SVM, bez wsparcia znacznym preprocessingiem danych, nie radzi sobie z niebalansowanymi, wieloklasowymi zbiorami.

4.6 Analiza nadmiernego dopasowania (Overfitting)

W celu oceny zjawiska przeuczenia porównano dokładność na zbiorze treningowym i testowym dla modelu hybrydowego ($T = 50$, $p_{svm} = 50\%$, $C = 10,0$).



Rysunek 5: Porównanie dokładności na zbiorze treningowym i testowym (Train vs Test) dla $T = 50$, $p_{svm} = 50\%$, $C = 10,0$.

Wnioski:

- Na zbiorze Mushroom (rys. 5a) przeuczenie nie występuje ($\Delta \approx 0$). Model idealnie generalizuje.
- Na zbiorze Breast Cancer (rys. 5b) różnica między zbiorem treningowym a testowym wynosi około 2,3 p.p., co jest wartością niską i akceptowalną.
- Na zbiorach Wine Quality oraz Car Evaluation różnice wynoszą odpowiednio ok. 3,9 p.p. i 3,7 p.p. Jest to umiarkowany poziom przeuczenia, typowy dla metod zespołowych na trudniejszych zbiorach danych.
- Ogólnie, model hybrydowy wykazał dobrą zdolność do generalizacji, z umiarkowanym przeuczeniem na bardziej złożonych zbiorach danych.

5 Podsumowanie i wnioski końcowe

Zrealizowany projekt pozwolił na zbadanie właściwości hybrydowego lasu klasyfikacyjnego łączącego drzewa ID3 z klasyfikatorami SVM.

- Uzyskane optymalne parametry modelu hybrydowego to: liczba estymatorów $T = 50$, udział SVM $p_{svm} = 50\%$, regularyzacja SVM $C = 10,0$.

1. Czego się nauczyliśmy:

- Jak dobór klasyfikatora bazowego zależy od charakteru danych: SVM (liniowy) preferuje zbiory (w przybliżeniu) liniowo separowalne, natomiast ID3 lepiej radzi sobie z nieliniowymi zależnościami oraz danymi kategorycznymi.
- Eksperyment na zbiorze *Synthetic Diagonal* potwierdził przewagę liniowego SVM w problemach z ukośną, liniową granicą decyzyjną, gdzie klasyczne, drzewa decyzyjne mają trudności z aproksymacją funkcji.
- Jak istotna jest różnorodność estymatorów w zespole: zastosowanie *Random Subspace Method* (domyślnie $m = \sqrt{M}$) okazało się kluczowe, aby modele w lesie podejmowały odmienne decyzje i żeby głosowanie miało sens.
- Jak interpretować wyniki eksperymentów: analiza wariancji (odchylenia standardowego) oraz macierzy pomyłek pozwala lepiej ocenić zachowanie, efektywność modelu niż sama dokładność.